

Exercise

s-takano

```
set.seed(29)
```

```
library(LearnBayes)
```

2-1

事前分布の設定

```
p = seq(0, 1, by=0.125)
```

```
prior = c(0.001, 0.001, 0.950, 0.008, 0.008, 0.008, 0.008, 0.008, 0.008)
```

```
sum(prior)
```

```
## [1] 1
```

尤度関数

```
likelihood = function (p) p ^ 6 * (1 - p) ^ 4
```

事後分布

```
posterior = c()
```

```
for (i in 1:length(p)) {
```

```
  posterior = c(posterior, likelihood(p[i]) * prior[i])
```

```
}
```

```
posterior = posterior / sum(posterior)
```

```
round(cbind(p, prior, posterior), 3)
```


```
##           p prior posterior
## [1,] 0.000 0.001      0.000
## [2,] 0.125 0.001      0.000
## [3,] 0.250 0.950      0.730
## [4,] 0.375 0.008      0.034
## [5,] 0.500 0.008      0.078
```

```
## [6,] 0.625 0.008 0.094
## [7,] 0.750 0.008 0.055
## [8,] 0.875 0.008 0.009
## [9,] 1.000 0.008 0.000
```

2-2

事前分布


```
midpt = seq(0.05, 0.95, by = 0.1)
prior = rep(0.1, 10) # 無情報事前分布
curve(histprior(x, midpt, prior), from = 0, to = 1)
```



事後分布

```
p = seq(0, 1, length = 500)
posterior = c()
for (i in length(p)) {
  min_idx = which.min(abs(midpt - p[i]))
  posterior = c(posterior, dbeta(p, 10, 10) * prior[min_idx]) # コイン Head
  10, Tail = 10
}
posterior = posterior / sum(posterior)
```


```
ps = sample(p, replace = TRUE, prob = posterior)
hist(ps)
```



2-3

事前分布


```
p = seq(0, 1, length=100)
plot(p, dbeta(p, 1, 1), type = "l")
```



事後分布

```
p = seq(0, 1, length=100)
```

```
plot(p, dbeta(p, 23, 8), type = "l")
```



(a)


```
qbeta(c(0.5, 0.95), 23, 8)
```

```
## [1] 0.7471911 0.8598149
```

(b)

```
q = seq(0, 1, length=100)
```

```
plot(q, pbeta(q, 23, 8), type="l")
```



```
1 - pbeta(0.6, 23, 8)
```

```
## [1] 0.9564759
```

(c)

```
sample = rbeta(1000, 23, 8)
```

```
sample[1:100]
```

```
## [1] 0.8070411 0.8255705 0.8477878 0.8108964 0.5317507 0.6689845  
0.7476998
```

```
## [8] 0.5928586 0.8221321 0.6747017 0.8718341 0.6920089 0.6583218  
0.6658947
```

```
## [15] 0.7164831 0.7388286 0.7370553 0.6340145 0.5931665 0.8259576  
0.8674522
```

```

## [22] 0.6588919 0.7786812 0.8250223 0.7543352 0.7646318 0.8076675
0.7075955
## [29] 0.5620429 0.6311084 0.7760624 0.7828018 0.8001533 0.7533651
0.7204592
## [36] 0.7126806 0.6963089 0.7200499 0.7241966 0.6954281 0.7771320
0.7758104
## [43] 0.7877369 0.6878208 0.6566363 0.7038708 0.7457192 0.7594498
0.7318217
## [50] 0.7833370 0.7323663 0.7595893 0.8384151 0.7640964 0.7508796
0.7798371
## [57] 0.8113989 0.7495155 0.7004356 0.8477141 0.7682620 0.8378440
0.8100615
## [64] 0.7901226 0.7423015 0.7588627 0.8255460 0.7433915 0.7981177
0.6595531
## [71] 0.6546487 0.7899955 0.8291286 0.7201989 0.7269412 0.8071294
0.6084613
## [78] 0.7088205 0.5755315 0.5836573 0.8408905 0.6462143 0.7539278
0.7029940
## [85] 0.6070669 0.8072564 0.6368789 0.7252253 0.6867064 0.7091260
0.7579631
## [92] 0.7055456 0.7030036 0.7053452 0.6349164 0.5357193 0.7662252
0.8386757
## [99] 0.6946933 0.7423767

```

(d)

さらに、10 人いる場合の高校を卒業する人数 X の予測分布を求める.

$$p(x) = \int_0^1 \binom{10}{x} p^x (1-p)^{10-x} \text{Beta}(p|23, 8) dp$$

$$\begin{aligned}
p(X=9) &= \int_0^1 \binom{10}{9} p^9 (1-p)^{10-9} \text{Beta}(p|23, 8) dp \\
&= \int_0^1 10 \cdot p^9 (1-p) \text{Beta}(p|23, 8) dp \\
&= \frac{10}{B(23, 8)} \int_0^1 p^9 (1-p) p^{22} (1-p)^7 dp \\
&= \frac{10}{B(23, 8)} \int_0^1 p^{31} (1-p)^8 dp \\
&= \frac{10}{B(23, 8)} \int_0^1 p^{32-1} (1-p)^{9-1} dp \\
&= \frac{10}{B(23, 8)} B(32, 9)
\end{aligned}$$

```
10 * beta(32, 9) / beta(23, 8)
```

```
## [1] 0.1902656
```

$$\begin{aligned}
p(X=10) &= \int_0^1 \binom{10}{10} p^{10} (1-p)^{10-10} \text{Beta}(p|23, 8) dp \\
&= \int_0^1 p^{10} \text{Beta}(p|23, 8) dp \\
&= \frac{1}{B(23, 8)} \int_0^1 p^{10} p^{22} (1-p)^7 dp \\
&= \frac{1}{B(23, 8)} \int_0^1 p^{32} (1-p)^7 dp \\
&= \frac{1}{B(23, 8)} \int_0^1 p^{33-1} (1-p)^{8-1} dp \\
&= \frac{1}{B(23, 8)} B(33, 8)
\end{aligned}$$

```
beta(33, 8) / beta(23, 8)
```

```
## [1] 0.07610622
```

サンプリングすると以下のようにできる.

よって、このときの $X = 9$ or $X = 10$ となる確率を求めれば良い.

$$p \sim \text{Beta}(p|23, 8) x \sim \text{Bin}(x|10, p)$$

```
p = rbeta(10000, 23, 8)
x = rbinom(10000, 10, p)
table(x) / 10000
```

```
## x
##      1      2      3      4      5      6      7      8      9     10
## 0.0002 0.0024 0.0094 0.0322 0.0787 0.1480 0.2250 0.2493 0.1818 0.0730
```

理論値と近い値となっていることが確認できる.

2-4

(a)

```
p = seq(0.1, 0.5, by=0.1)
```

```
p
```

```
## [1] 0.1 0.2 0.3 0.4 0.5
```

```
prior = c(0.50, 0.2, 0.2, 0.05, 0.05)
```

```
mean = sum(p * prior)
```

```
mean
```

```
## [1] 0.195
```

```
sd = sqrt(sum((p - mean)^2 * prior))
```

```
sd
```

```
## [1] 0.1160819
```

$Beta(p|3, 12)$ の場合、サンプリング近似を行う.

```
sample = rbeta(10000, shape1 = 3, shape2 = 12)
```

```
mean(sample)
```

```
## [1] 0.1993212
```

```
sd(sample)
```

```
## [1] 0.1002495
```

(b)

通学者数 Y に関して、以下の予測分布が計算できる.

■ 離散事前分布

$$p(y) = \sum_p \binom{12}{y} p^y (1-p)^{12-y} g(p)$$


```

predict = c()
for (y in 0:12) {
  p_y = 0
  for (i in 1:length(p)) {
    p_y = p_y + choose(12, y) * p[i]^y * (1 - p[i])^(12 - y) * prior[i]
  }
  predict = c(predict, p_y)
}
predict

## [1] 0.1578479672 0.2447719936 0.2093137913 0.1475812240 0.1001416403
## [6] 0.0652427436 0.0393037888 0.0212231429 0.0098095892 0.0036170714
## [11] 0.0009692955 0.0001645993 0.0000131530

plot(0:12, predict, type = "l")

```




```

pdiscp(p, prior, 12, 0:12)

```

```
## [1] 0.1578479672 0.2447719936 0.2093137913 0.1475812240 0.1001416403
## [6] 0.0652427436 0.0393037888 0.0212231429 0.0098095892 0.0036170714
## [11] 0.0009692955 0.0001645993 0.0000131530
```

```
plot(0:12, pdiscp(p, prior, 12, 0:12), type = "l")
```



■ベータ分布

$$\begin{aligned}
 p(y) &= \int_0^1 \binom{12}{y} p^y (1-p)^{12-y} \frac{1}{B(3, 12)} p^{3-1} (1-p)^{12-1} dp \\
 &= \binom{12}{y} \frac{1}{B(3, 12)} \int_0^1 p^{y+2} (1-p)^{23-y} dp \\
 &= \binom{12}{y} \frac{1}{B(3, 12)} B(y+3, 24-y)
 \end{aligned}$$


```
predict = c()
for (y in 0:12) {
  p_y = choose(12, y) * beta(y + 3, 24 - y) / beta(3, 12)
  predict = c(predict, p_y)
}
predict
```

```
## [1] 1.400000e-01 2.191304e-01 2.191304e-01 1.739130e-01 1.173913e-01
## [6] 6.919908e-02 3.588101e-02 1.628214e-02 6.360210e-03 2.072957e-03
## [11] 5.330462e-04 9.691749e-05 9.422533e-06
```

```
sum(predict)
```

```
## [1] 1
```


```
plot(0:12, predict, type = "l")
```



```
pbetap(c(3, 12), 12, 0:12)
```

```
## [1] 1.400000e-01 2.191304e-01 2.191304e-01 1.739130e-01 1.173913e-01
## [6] 6.919908e-02 3.588101e-02 1.628214e-02 6.360210e-03 2.072957e-03
## [11] 5.330462e-04 9.691749e-05 9.422533e-06
```

```
plot(0:12, pbetap(c(3, 12), 12, 0:12), type = "l")
```



2-5

(a)

```
mu = seq(20, 70, by = 10)
prior = c(0.1, 0.15, 0.25, 0.25, 0.15, 0.1)
mu
```

```
## [1] 20 30 40 50 60 70
```

```
prior
```

```
## [1] 0.10 0.15 0.25 0.25 0.15 0.10
```

(b)

```
y = c(38.6, 42.4, 57.5, 40.5, 51.7, 67.1, 33.4, 60.9, 64.1, 40.1, 40.7,
      6.4)
```

```
ybar = mean(y)
```

```
ybar
```

```
## [1] 45.28333
```

```

(c)
likelihood = function (mu) exp(-1 * length(y) / (2 * 100) * (mu - ybar)^2)
like = likelihood(mu)
like

## [1] 2.201480e-17 8.192991e-07 1.873425e-01 2.632064e-01 2.272076e-06
## [6] 1.205079e-16

```

```

(d)
post = prior * like
post = post / sum(post)
post

## [1] 1.954479e-17 1.091063e-06 4.158078e-01 5.841881e-01 3.025731e-06
## [6] 1.069871e-16

```

```

(e)
dist = cbind(mu, post)
dist

##      mu      post
## [1,] 20 1.954479e-17
## [2,] 30 1.091063e-06
## [3,] 40 4.158078e-01
## [4,] 50 5.841881e-01
## [5,] 60 3.025731e-06
## [6,] 70 1.069871e-16

```

```

discint(dist, 0.8)

## $prob
## [1] 0.9999959
##
## $set
## [1] 40 50

```

2-6

(a)

```
lambda = c(0.5, 1, 1.5, 2, 2.5, 3)
prior = c(0.1, 0.2, 0.3, 0.2, 0.15, 0.05)
likelihood = function (lambda) exp(-6 * lambda) * (6 * lambda)^12
post = prior * likelihood(lambda)
post = post / sum(post)
cbind(lambda, prior, round(post, 2))
```

```
##      lambda prior
## [1,]      0.5  0.10 0.00
## [2,]      1.0  0.20 0.04
## [3,]      1.5  0.30 0.36
## [4,]      2.0  0.20 0.37
## [5,]      2.5  0.15 0.20
## [6,]      3.0  0.05 0.03
```

(b)

$$p(y|\lambda) = \exp(-\lambda) \frac{\lambda^y}{y!}$$

7日間故障が起きない確率は、 $p(y=0)^7$

$$p(y=0|\lambda)^7 = \exp(-\lambda)^7 = \exp(-7\lambda)$$

よって、予測確率は

$$p(y=0) = \sum_{\lambda} p(y=0|\lambda)p(\lambda)$$

```
predict = 0
for (i in 1:length(lambda)) {
  predict = predict + exp(-7 * lambda[i]) * post[i]
}
predict

## [1] 4.640932e-05
```

3-1

```
y = c(0, 10, 9, 8, 11, 3, 3, 8, 8, 11)
```

(a)

```
grid = seq(-2, 12, by = 0.1)
```

grid

```
## [1] -2.0 -1.9 -1.8 -1.7 -1.6 -1.5 -1.4 -1.3 -1.2 -1.1 -1.0 -0.9 -0.8
    -0.7 -0.6
## [16] -0.5 -0.4 -0.3 -0.2 -0.1  0.0  0.1  0.2  0.3  0.4  0.5  0.6  0.7
    0.8  0.9
## [31]  1.0  1.1  1.2  1.3  1.4  1.5  1.6  1.7  1.8  1.9  2.0  2.1  2.2
    2.3  2.4
## [46]  2.5  2.6  2.7  2.8  2.9  3.0  3.1  3.2  3.3  3.4  3.5  3.6  3.7
    3.8  3.9
## [61]  4.0  4.1  4.2  4.3  4.4  4.5  4.6  4.7  4.8  4.9  5.0  5.1  5.2
    5.3  5.4
## [76]  5.5  5.6  5.7  5.8  5.9  6.0  6.1  6.2  6.3  6.4  6.5  6.6  6.7
    6.8  6.9
## [91]  7.0  7.1  7.2  7.3  7.4  7.5  7.6  7.7  7.8  7.9  8.0  8.1  8.2
    8.3  8.4
## [106]  8.5  8.6  8.7  8.8  8.9  9.0  9.1  9.2  9.3  9.4  9.5  9.6  9.7
    9.8  9.9
## [121] 10.0 10.1 10.2 10.3 10.4 10.5 10.6 10.7 10.8 10.9 11.0 11.1 11.2
    11.3 11.4
## [136] 11.5 11.6 11.7 11.8 11.9 12.0
```

(b)

```
post = c()
```

```
for (i in 1:length(grid)) {
```

```
  post = c(post, prod(1 / (1 + (y - grid[i])^2)))
```

```
}
```

```
post = post / sum(post)
```

```
post
```


```

## [1] 1.126701e-12 1.496731e-12 1.998369e-12 2.681960e-12 3.618341e-12
## [6] 4.907571e-12 6.691425e-12 9.171224e-12 1.263306e-11 1.748306e-11
## [11] 2.429564e-11 3.387761e-11 4.734937e-11 6.624058e-11 9.259000e-11
## [16] 1.290277e-10 1.788063e-10 2.457439e-10 3.340655e-10 4.481838e-10
## [21] 5.925432e-10 7.716980e-10 9.907641e-10 1.256265e-09 1.577282e-09
## [26] 1.966808e-09 2.443283e-09 3.032471e-09 3.769918e-09 4.704408e-09
## [31] 5.902894e-09 7.457609e-09 9.496316e-09 1.219707e-08 1.580947e-08
## [36] 2.068510e-08 2.732094e-08 3.642051e-08 4.897829e-08 6.639260e-08
## [41] 9.060846e-08 1.242817e-07 1.709331e-07 2.350204e-07 3.217946e-07
## [46] 4.367471e-07 5.844460e-07 7.667233e-07 9.805828e-07 1.216761e-06
## [51] 1.460147e-06 1.692662e-06 1.897806e-06 2.064831e-06 2.190700e-06
## [56] 2.279372e-06 2.339409e-06 2.381300e-06 2.415471e-06 2.451242e-06
## [61] 2.496573e-06 2.558281e-06 2.642503e-06 2.755231e-06 2.902879e-06
## [66] 3.092862e-06 3.334235e-06 3.638441e-06 4.020242e-06 4.498945e-06
## [71] 5.100067e-06 5.857626e-06 6.817372e-06 8.041376e-06 9.614637e-06
## [76] 1.165467e-05 1.432560e-05 1.785902e-05 2.258530e-05 2.898085e-05
## [81] 3.774050e-05 4.988895e-05 6.695444e-05 9.124112e-05 1.262594e-04
## [86] 1.774089e-04 2.530649e-04 3.663029e-04 5.376134e-04 7.991090e-04
## [91] 1.200852e-03 1.819899e-03 2.772146e-03 4.225372e-03 6.408220e-03
## [96] 9.603697e-03 1.410919e-02 2.014539e-02 2.771668e-02 3.647081e-02
## [101] 4.565149e-02 5.422549e-02 6.116538e-02 6.574884e-02 6.771668e-02
## [106] 6.723693e-02 6.474535e-02 6.077250e-02 5.582661e-02 5.034240e-02
## [111] 4.467224e-02 3.909187e-02 3.380540e-02 2.894759e-02 2.458832e-02
## [116] 2.074307e-02 1.738861e-02 1.448031e-02 1.196713e-02 9.801610e-03
## [121] 7.944263e-03 6.363233e-03 5.031358e-03 3.923044e-03 3.012578e-03
## [126] 2.274241e-03 1.683455e-03 1.217945e-03 8.581987e-04 5.871043e-04
## [131] 3.891602e-04 2.498625e-04 1.556626e-04 9.443623e-05 5.606765e-05
## [136] 3.275997e-05 1.894430e-05 1.089840e-05 6.264988e-06 3.611696e-06
## [141] 2.093835e-06


```

(c)

```
plot(grid, post, type = "l")
```

(d)
`ps = sample(grid, replace = TRUE, prob = post)`
`hist(ps)`



```
mean(ps)
```

```
## [1] 8.588652
```

```
sd(ps)
```

```
## [1] 0.6105141
```

3-2

(a)

$$g(\lambda|data) \propto \lambda^{-n-1} \exp\left(-\frac{s}{\lambda}\right)$$

$$\begin{aligned} g(\theta|data) &\propto \theta^{n+1} \exp(-s\theta) \cdot \left| \frac{d\lambda}{d\theta} \right| \\ \theta = \frac{1}{\lambda} &= \theta^{n+1} \exp(-s\theta) \cdot \left| \frac{d}{d\theta} \theta^{-1} \right| \\ &= \theta^{n+1} \exp(-s\theta) \cdot |-1 \cdot \theta^{-2}| \\ &= \theta^{n-1} \exp(-s\theta) \end{aligned}$$

(b)

1つの電球が切れるまでの時間を X とすると、 $X \sim \text{Exp}(x|\beta)$ と考えられる。


```
x = c(751, 594, 1213, 1126, 819)
```

```
n = length(x)
```


```
s = sum(x)
```

```
theta = rgamma(1000, n, s)
```

```
hist(theta)
```



(c)
 $\text{lambda} = 1 / \text{theta}$
`hist(lambda)`



(d)
`length(lambda[lambda > 1000]) / 1000`

```
## [1] 0.471
```


3-3

$$g(N|y) \propto \frac{1}{N^n}, \quad y_{(n)} \leq N \leq B$$

ここで、 N は最大値の分布であることから、 y_1, \dots, y_n を観測した際には、初期の候補 $1 \leq N \leq B$ から上記へと分布が縮小する。(観測値の最大値以上の値になる)

(a)
`n = 5`
`y = c(43, 24, 100, 35, 85)`
`B = 200`
`grid = seq(max(y), B, by = 1)`
`post = 1 / grid^n`
`post = post / sum(post)`

```
plot(grid, post)
```



(b)

```
N = sample(grid, size = 1000, replace = TRUE, prob = post)
```

```
mean(N)
```

```
## [1] 125.043
```

```
sd(N)
```

```
## [1] 23.26539
```

(c)

```
length(N[N > 150]) / 1000
```

```
## [1] 0.158
```

3-4


(a)

■ P1

```

m = 1000
p1 = rbeta(m, 100, 100)
hist(p1)

```



```

length(p1[0.44 < p1 & p1 < 0.56]) / m

```

```

## [1] 0.914


```

■P2

```

q = function (p) 0.9 * dbeta(p, 500, 500) + 0.1 * dbeta(p, 1, 1)
p = seq(0.4, 0.6, length = 1000)
plot(p, q(p))


```



```

m = 10000 # 1000 では分布の形を見るのには少ない
p2_sampling = function () {
  x = sample(c(0, 1), 1, prob = c(0.1, 0.9))
  if (x == 1) {
    return(rbeta(1, 500, 500))
  } else {
    return(rbeta(1, 1, 1))
  }
}
p2 = replicate(m, p2_sampling())
hist(p2, xlim = c(0.4, 0.6), breaks=seq(0, 1, 0.005))

```



```
length(p2[0.44 < p2 & p2 < 0.56]) / m
```

```
## [1] 0.9121
```

(b)

尤度は以下ようになる.


$$L(p) = \binom{100}{45} p^{45} (1-p)^{55}$$

■P1

事後分布は、事前分布が³ $Beta(100, 100)$ で、表が³ 45 回出ているので、 $Beta(145, 155)$ となる.

$$\begin{aligned} p(p|data) &\propto L(p)g(p) \\ &= \binom{100}{45} p^{45} (1-p)^{55} Beta(p|100, 100) \\ &\propto p^{45} (1-p)^{55} p^{100-1} (1-p)^{100-1} \\ &= p^{45+100-1} (1-p)^{55+100-1} \end{aligned}$$


```
p1 = rbeta(1000, 145, 155)
hist(p1)
```



```
quantile(p1, c(0.05, 0.95))
```

```
##           5%           95%
## 0.4348357 0.5342714
```

■P2

事後分布は、以下のようなになる。

$$\begin{aligned}
p(p|data) &\propto L(p)g(p) \\
&= \binom{100}{45} p^{45} (1-p)^{55} \{0.9 \text{Beta}(p|500, 500) + 0.1 \text{Beta}(p|1, 1)\} \\
&= 0.9 \cdot \binom{100}{45} p^{45} (1-p)^{55} \text{Beta}(p|500, 500) + 0.1 \cdot \binom{100}{45} p^{45} (1-p)^{55} \text{Beta}(p|1, 1) \\
&= 0.9 \cdot \binom{100}{45} p^{45} (1-p)^{55} \frac{1}{B(500, 500)} p^{500-1} (1-p)^{500-1} + 0.1 \cdot \binom{100}{45} p^{45} (1-p)^{55} \frac{1}{B(1, 1)} p^{1-1} (1-p)^{1-1} \\
&\propto 0.9 \cdot \frac{1}{B(500, 500)} p^{500+45-1} (1-p)^{500+55-1} + 0.1 \cdot \frac{1}{B(1, 1)} p^{1+45-1} (1-p)^{1+55-1} \\
&= 0.9 \cdot \frac{1}{B(500, 500)} p^{500+45-1} (1-p)^{500+55-1} + 0.1 \cdot p^{1+45-1} (1-p)^{1+55-1} \\
&= 0.9 \cdot \frac{B(545, 555)}{B(500, 500)} \frac{1}{B(545, 555)} p^{500+45-1} (1-p)^{500+55-1} + 0.1 \cdot B(46, 56) \frac{1}{B(46, 56)} p^{1+45-1} (1-p)^{1+55-1} \\
&= 0.9 \cdot \frac{B(545, 555)}{B(500, 500)} \text{Beta}(p|545, 555) + 0.1 \cdot B(46, 56) \text{Beta}(p|46, 56)
\end{aligned}$$

$\int \text{Beta}(p|545, 555) dp = 1, \int \text{Beta}(p|46, 56) dp = 1$ より、混合比率に関しては、混合比率を γ とすると、以下の式になる。

$$\gamma : 1 - \gamma = 0.9 \cdot \frac{B(545, 555)}{B(500, 500)} : 0.1 \cdot B(46, 56)$$

$$\begin{aligned}
(1 - \gamma) \cdot (0.9 \cdot \frac{B(545, 555)}{B(500, 500)}) &= \gamma \cdot 0.1 \cdot B(46, 56) \\
(0.9 \cdot \frac{B(545, 555)}{B(500, 500)}) - \gamma \cdot (0.9 \cdot \frac{B(545, 555)}{B(500, 500)}) &= \gamma \cdot 0.1 \cdot B(46, 56) \\
\{(0.9 \cdot \frac{B(545, 555)}{B(500, 500)}) + 0.1 \cdot B(46, 56)\} \gamma &= (0.9 \cdot \frac{B(545, 555)}{B(500, 500)})
\end{aligned}$$

$$\gamma = \frac{(0.9 \cdot \frac{B(545, 555)}{B(500, 500)})}{(0.9 \cdot \frac{B(545, 555)}{B(500, 500)}) + 0.1 \cdot B(46, 56)}$$

よって、各項の係数は以下ようになる。

```

tmp = exp(lbeta(545, 555) - lbeta(500, 500)) # overflow するので、log で計算
gamma = (0.9 * tmp) / (0.9 * tmp + 0.1 * beta(46, 56))
gamma

## [1] 0.9777615


1 - gamma

```

```
## [1] 0.02223847
```

`m = 10000` # 1000 では分布の形を見るのには少ない

```
p2_sampling = function () {  
  x = sample(c(0, 1), 1, prob = c(0.0222, 0.9778))  
  if (x == 1) {  
    return(rbeta(1, 545, 555))  
  } else {  
    return(rbeta(1, 46, 56))  
  }  
}  
  
p2 = replicate(m, p2_sampling())  
hist(p2, xlim = c(0.4, 0.6), breaks=seq(0, 1, 0.005))
```



```
quantile(p2, c(0.05, 0.95))
```

```
##          5%          95%
```

```
## 0.4683059 0.5202097
```

LearnBayes を用いると以下になる.

```
probs = c(0.9, 0.1)
```

```

beta.par1 = c(500, 500)
beta.par2 = c(1, 1)
betapar = rbind(beta.par1, beta.par2)
data = c(45, 55)
post = binomial.beta.mix(probs, betapar, data)
post

## $probs
##  beta.par1  beta.par2
## 0.97776153 0.02223847
##
## $betapar
##           [,1] [,2]
## beta.par1  545  555
## beta.par2   46   56

```


(c)

■P1

```

p1 = rbeta(1000, 130, 170)
hist(p1)

```



```
quantile(p1, c(0.05, 0.95))
```

```
##           5%           95%
## 0.3852962 0.4818855
```

■P2

同様な計算から、

$$\begin{aligned}
 p(p|data) &\propto L(p)g(p) \\
 &= 0.9 \cdot \frac{B(530, 570)}{B(500, 500)} f_B(p; 530, 570) + 0.1 \cdot B(31, 71) f_B(p; 31, 71)
 \end{aligned}$$

混合比率に関しても同様に、

$$\gamma = \frac{(0.9 \cdot \frac{B(530, 570)}{B(500, 500)})}{(0.9 \cdot \frac{B(530, 570)}{B(500, 500)}) + 0.1 \cdot B(31, 71)}$$

よって、各項の係数は以下ようになる。

```
tmp = exp(lbeta(530, 570) - lbeta(500, 500)) # overflow するので、log で計算
```

```

gamma = (0.9 * tmp) / (0.9 * tmp + 0.1 * beta(31, 71))
gamma

## [1] 0.0399307


1 - gamma

## [1] 0.9600693

m = 10000 # 1000 では分布の形を見るのには少ない
p2_sampling = function () {
  x = sample(c(0, 1), 1, prob = c(0.0399, 0.9601))
  if (x == 1) {
    return(rbeta(1, 530, 570))
  } else {
    return(rbeta(1, 31, 71))
  }
}
p2 = replicate(m, p2_sampling())
hist(p2, xlim = c(0.4, 0.6), breaks=seq(0, 1, 0.005))

```

Histogram of p2



```
quantile(p2, c(0.05, 0.95))
```

```
##          5%          95%
## 0.4458550 0.5062934
```

LearnBayes を用いると以下になる.

```
probs = c(0.9, 0.1)
beta.par1 = c(500, 500)
beta.par2 = c(1, 1)
betapar = rbind(beta.par1, beta.par2)
data = c(30, 70)
post = binomial.beta.mix(probs, betapar, data)
post
```

```
## $probs
## beta.par1 beta.par2
## 0.0399307 0.9600693
##
## $betapar
##          [,1] [,2]
## beta.par1  530  570
## beta.par2   31   71
```

(d)

	45	30
P1	0.4348357 ~ 0.5342714	0.3852962 ~ 0.4818855
P2	0.4683059 ~ 0.5202097	0.4458550 ~ 0.5062934

上記の表から、P2の方が頑健性が高い。

3-5

(a)

$$p(X=8) = \binom{20}{8} p^8 (1-p)^{20-8}$$

```
dbinom(8, 20, 0.2)
```

```
## [1] 0.02216088
```


```
choose(20, 8) * (0.2) ^ 8 * (1 - 0.2) ^ (20 - 8)
```

```
## [1] 0.02216088
```

(b)

$$g(p) = 0.5I(p = 0.2) + 0.5I(p \neq 0.2)Beta(p|1,4)$$

```
q = function (p) {
  if (p == 0.2) {
    return(0.5)
  } else {
    return(0.5 * dbeta(p, 1, 4))
  }
}
p = seq(0, 1, by = 0.01)
plot(p, lapply(p, q), type = "l")
```



$$\begin{aligned}
p(p|data) &\propto L(p)g(p) \\
&= \binom{20}{8} p^8 (1-p)^{20-8} \{0.5I(p=0.2) + 0.5I(p \neq 0.2)Beta(p|1, 4)\} \\
&= \binom{20}{8} p^8 (1-p)^{20-8} \frac{1}{2} I(p=0.2) + \binom{20}{8} p^8 (1-p)^{20-8} \frac{1}{2} I(p \neq 0.2) Beta(p|1, 4) \\
&\propto p^8 (1-p)^{20-8} I(p=0.2) + p^8 (1-p)^{20-8} I(p \neq 0.2) Beta(p|1, 4) \\
&= p^8 (1-p)^{20-8} I(p=0.2) + p^8 (1-p)^{20-8} I(p \neq 0.2) \frac{1}{B(1, 4)} p^{1-1} (1-p)^{4-1} \\
&= p^8 (1-p)^{20-8} I(p=0.2) + I(p \neq 0.2) \frac{1}{B(1, 4)} p^{9-1} (1-p)^{16-1} \\
&= p^8 (1-p)^{20-8} I(p=0.2) + I(p \neq 0.2) \frac{B(9, 16)}{B(1, 4)} Beta(p|9, 16)
\end{aligned}$$

$\int Beta(p|9, 16) = 1$ と $p^8 (1-p)^{20-8} I(p=0.2) = (0.2)^8 (1-0.2)^{12}$ より、係数に関しては以下のようなになる．

$$\gamma : 1 - \gamma = (0.2)^8 (1-0.2)^{12} : \frac{B(9, 16)}{B(1, 4)}$$

$$\begin{aligned}
(1 - \gamma) \cdot (0.2)^8 (1-0.2)^{12} &= \gamma \cdot \frac{B(9, 16)}{B(1, 4)} \\
(0.2)^8 (1-0.2)^{12} - \gamma \cdot (0.2)^8 (1-0.2)^{12} &= \gamma \cdot \frac{B(9, 16)}{B(1, 4)}
\end{aligned}$$

$$\gamma = \frac{(0.2)^8 (1-0.2)^{12}}{(0.2)^8 (1-0.2)^{12} + \frac{B(9, 16)}{B(1, 4)}}$$

```

gamma = (0.2 ^ 8 * (1 - 0.2)^12) / (0.2 ^ 8 * (1 - 0.2)^12 + beta(9, 16) /
    beta(1, 4))
gamma

```

```
## [1] 0.3410395
```

```
1 - gamma
```

```
## [1] 0.6589605
```

よって、今回の結果だと、 $p = 0.2$ のときは、0.3410 となる．一方で、(a) の結果は、0.02216088 である．

```


q = function (p) {
  if (p == 0.2) {
    return(0.341)
  } else {

```

```

    return(0.659 * dbeta(p, 9, 16))
  }
}
p = seq(0, 1, by = 0.01)
plot(p, lapply(p, q), type = "l")

```



LearnBayes を用いると、以下になる.

```
pbetat(0.2, .5, c(1, 4), c(8, 12))
```

```
## $bf
## [1] 0.5175417
##
## $post
## [1] 0.3410395
```

(c)

■(1)


$$g(p) = 0.5I(p = 0.2) + 0.5I(p \neq 0.2)Beta(p|0.5, 2)$$

```
q = function (p) {
```

```

if (p == 0.2) {
  return(0.5)
} else {
  return(0.5 * dbeta(p, 0.5, 2))
}
}
p = seq(0, 1, by = 0.01)
plot(p, lapply(p, q), type = "l")

```



$$\begin{aligned}
 p(p|data) &\propto L(p)g(p) \\
 &= p^8(1-p)^{20-8}I(p=0.2) + I(p \neq 0.2) \frac{B(8.5, 14)}{B(0.5, 2)} \text{Beta}(p|8.5, 14)
 \end{aligned}$$

$\int \text{Beta}(p|8.5, 14) = 1$ と $p^8(1-p)^{20-8}I(p=0.2) = (0.2)^8(1-0.2)^{12}$ より、係数に関しては以下のようになる。

$$\begin{aligned}
 \gamma : 1 - \gamma &= (0.2)^8(1-0.2)^{12} : \frac{B(8.5, 14)}{B(0.5, 2)} \\
 \gamma &= \frac{(0.2)^8(1-0.2)^{12}}{(0.2)^8(1-0.2)^{12} + \frac{B(8.5, 14)}{B(0.5, 2)}}
 \end{aligned}$$

```

gamma = (0.2 ^ 8 * (1 - 0.2)^12) / (0.2 ^ 8 * (1 - 0.2)^12 + beta(8.5, 14)/
  beta(0.5, 2))

```

```
gamma
```

```
## [1] 0.3900752
```

```
1 - gamma
```

```
## [1] 0.6099248
```

```
pbetat(0.2, .5, c(0.5, 2), c(8, 12))
```

```
## $bf
```

```
## [1] 0.6395464
```

```
##
```


```
## $post
```

```
## [1] 0.3900752
```

```
■(2)
```

$$g(p) = 0.5I(p = 0.2) + 0.5I(p \neq 0.2)Beta(p|2, 8)$$

```
q = function (p) {  
  if (p == 0.2) {  
    return(0.5)  
  } else {  
    return(0.5 * dbeta(p, 2, 8))  
  }  
}  
p = seq(0, 1, by = 0.01)  
plot(p, lapply(p, q), type = "l")
```



$$p(p|data) \propto L(p)g(p)$$

$$= p^8(1-p)^{20-8}I(p=0.2) + I(p \neq 0.2) \frac{B(10,20)}{B(2,8)} \text{Beta}(p|10,20)$$

$\int \text{Beta}(p|8.5, 14) = 1$ と $p^8(1-p)^{20-8}I(p=0.2) = (0.2)^8(1-0.2)^{12}$ より、係数に関しては以下のようになる.

$$\gamma : 1 - \gamma = (0.2)^8(1-0.2)^{12} : \frac{B(10,20)}{B(2,8)} \gamma = \frac{(0.2)^8(1-0.2)^{12}}{(0.2)^8(1-0.2)^{12} + \frac{B(10,20)}{B(2,8)}}$$

```
gamma = (0.2 ^ 8 * (1 - 0.2)^12) / (0.2 ^ 8 * (1 - 0.2)^12 + beta(10, 20)/
  beta(2, 8))
```

```
gamma
```

```
## [1] 0.328591
```

```
1 - gamma
```

```
## [1] 0.671409
```

```
pbetat(0.2, .5, c(2, 8), c(8, 12))
```

```
## $bf
```


```
## [1] 0.4894051
```

```
##
## $post
## [1] 0.328591
```

■(3)

$$g(p) = 0.5I(p = 0.2) + 0.5I(p \neq 0.2)Beta(p|8, 32)$$

```
q = function (p) {
  if (p == 0.2) {
    return(0.5)
  } else {
    return(0.5 * dbeta(p, 8, 32))
  }
}
p = seq(0, 1, by = 0.01)
plot(p, lapply(p, q), type = "l")
```



$$\begin{aligned}
 p(p|data) &\propto L(p)g(p) \\
 &= p^8(1-p)^{20-8}I(p = 0.2) + I(p \neq 0.2)\frac{B(16, 44)}{B(8, 32)}Beta(p|16, 44)
 \end{aligned}$$

$\int \text{Beta}(p|16, 44) = 1$ と $p^8(1-p)^{20-8}I(p=0.2) = (0.2)^8(1-0.2)^{12}$ より、係数に関しては以下のようになる.

$$\gamma : 1 - \gamma = (0.2)^8(1-0.2)^{12} : \frac{B(16, 44)}{B(8, 32)}$$

$$\gamma = \frac{(0.2)^8(1-0.2)^{12}}{(0.2)^8(1-0.2)^{12} + \frac{B(16, 44)}{B(8, 32)}}$$

```
gamma = (0.2 ^ 8 * (1 - 0.2)^12) / (0.2 ^ 8 * (1 - 0.2)^12 + beta(16, 44)/
  beta(8, 32))
gamma
```

```
## [1] 0.3855337
```

```
1 - gamma
```

```
## [1] 0.6144663
```

```
pbetat(0.2, .5, c(8, 32), c(8, 12))
```

```
## $bf
```

```
## [1] 0.6274287
```

```
##
```

```
## $post
```

```
## [1] 0.3855337
```

(d)

20 回中 8 回当ててる確率は 0.3 程度と考えられるので、ESP があるとは言えない。

3-6

速度平均 μ 、標準偏差 $\sigma = 10$ で正規分布であるので、70 マイルで追い越す確率は $P(\mu < 70) = \Phi(70, \mu, 10)$ である。よって、尤度は以下のように表せる。

$$L(\mu) \propto \Phi(70, \mu, 10)^s (1 - \Phi(70, \mu, 10))^f$$

(a)

事前分布は一様分布 ($f(x) = C \quad (-\infty < x < \infty)$) であるとする、

$$\begin{aligned}
 p(\mu|data) &\propto L(\mu)q(\mu) \\
 &= C \cdot \Phi(70, \mu, 10)(1 - \Phi(70, \mu, 10))^{17} \\
 &\propto \Phi(70, \mu, 10)(1 - \Phi(70, \mu, 10))^{17}
 \end{aligned}$$


グリッド近似を用いる

mu = seq(0, 200, by = 0.1) # 速度は 0 以上であるので、加えて、最大値は 200
とした。

```

p = function (mu) {
  pnorm(70, mu, 10) * (1 - pnorm(70, mu, 10))^17
}
plot(mu, p(mu) / sum(p(mu)), type = "l")

```



(b)

グリッド近似した際の、各グリッドの値を μ_i 、グリッド数を N とすると、事後平均は以下のように表せる。

$$Mean = \sum_{i=1}^N \mu_i \cdot p(\mu_i)$$

グリッド近似を用いる

mu = seq(0, 200, by = 0.1) # 速度は 0 以上であるので、加えて、最大値は 200
とした。


```

p = function (mu) {
  pnorm(70, mu, 10) * (1 - pnorm(70, mu, 10))^17
}
post = p(mu) / sum(p(mu))
sum(mu * post) # 事後平均

## [1] 87.11109

```

(c)

$P(\mu > 80)$ を求めればよいので、以下のようになる.

mu = seq(0, 150, by = 0.1) # 速度は 0 以上であるので、加えて、最大値は 200
とした.

```

p = function (mu) {
  pnorm(70, mu, 10) * (1 - pnorm(70, mu, 10))^17
}
post = p(mu) / sum(p(mu))
sum(cbind(mu, post)[mu > 80, 2])

## [1] 0.9300158

```

$P(\mu > 80) = 1 - P(\mu \leq 80) = 1 - \int_{-\infty}^{80} p(\mu) d\mu$ の数値積分は以下のようになる.

```

p = function (mu) {
  pnorm(70, mu, 10) * (1 - pnorm(70, mu, 10))^17
}
z = integrate(p, 0, 150)$value # 正規化定数
int = integrate(p, -Inf, 80)
1 - int$value / z

## [1] 0.9316374


```

80 マイル近傍の事後分布は以下のようになる.

```

mu = seq(0, 200, by = 0.1)
p = function (mu) {
  pnorm(70, mu, 10) * (1 - pnorm(70, mu, 10))^17
}
post = p(mu) / sum(p(mu))
plot(mu, post, xlim = c(70, 110), type = "l")

```



3-7


(a)

$$g(\lambda) = 0.5 \cdot \text{gamma}(\lambda|1.5, 1000) + 0.5 \cdot \text{gamma}(\lambda|7, 1000)$$

ガンマ分布は以下で定義する.

$$\text{gamma}(\lambda|\alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} \exp(-\beta\lambda) \quad (\lambda > 0)$$

```
lambda = seq(0, 1, by = 0.001)
g = function (lambda) {
  0.5 * dgamma(lambda, shape = 1.5, rate = 1000) + 0.5 * dgamma(lambda,
    shape = 7, rate = 1000)
}
plot(lambda, g(lambda), xlim = c(0, 0.1), type = "l")
```



(b)

死亡数 y は、暴露数 e と死亡率 λ としたとき、平均 $e\lambda$ のポアソン分布に従うと考えられる。

$$p(y) = Po(e\lambda) = \frac{(e\lambda)^y}{y!} \exp(-e\lambda)$$

よって、 $y = 4, e = 1767$ の時の、尤度は以下の用に表せる。

$$L(\lambda) = \frac{(1767\lambda)^4}{4!} \exp(-1767\lambda)$$

この時、 λ の事後分布は以下のようになる。

$$\begin{aligned} p(\lambda|data) &\propto L(\lambda)g(\lambda) \\ &= \frac{(1767\lambda)^4}{4!} \exp(-1767\lambda) \{0.5 \cdot \text{gamma}(\lambda|1.5, 1000) + 0.5 \cdot \text{gamma}(\lambda|7, 1000)\} \\ &\propto \lambda^4 \exp(-1767\lambda) \{\text{gamma}(\lambda|1.5, 1000) + \text{gamma}(\lambda|7, 1000)\} \\ &= \lambda^4 \exp(-1767\lambda) \left\{ \frac{1000^{1.5}}{\Gamma(1.5)} \lambda^{1.5-1} \exp(-1000\lambda) + \frac{1000^7}{\Gamma(7)} \lambda^{7-1} \exp(-1000\lambda) \right\} \\ &= \frac{1000^{1.5}}{\Gamma(1.5)} \lambda^{1.5+4-1} \exp(-2767\lambda) + \frac{1000^7}{\Gamma(7)} \lambda^{7+4-1} \exp(-2767\lambda) \\ &= \frac{1000^{1.5}}{\Gamma(1.5)} \frac{\Gamma(5.5)}{2767^{5.5}} \text{gamma}(\lambda|5.5, 2767) + \frac{1000^7}{\Gamma(7)} \frac{\Gamma(11)}{2767^{11}} \text{gamma}(\lambda|11, 2767) \end{aligned}$$

ここで、混合比率を π とすると、

$$\pi : 1 - \pi = \frac{1000^{1.5} \Gamma(5.5)}{\Gamma(1.5) 2767^{5.5}} : \frac{1000^7 \Gamma(11)}{\Gamma(7) 2767^{11}}$$

$$a = \frac{1000^{1.5} \Gamma(5.5)}{\Gamma(1.5) 2767^{5.5}}, b = \frac{1000^7 \Gamma(11)}{\Gamma(7) 2767^{11}}$$

$$\pi = \frac{a}{a + b}$$

```
a = (1000 ^ 1.5 * gamma(5.5)) / (gamma(1.5) * 2767 ^ 5.5)
b = (1000 ^ 7 * gamma(11)) / (gamma(7) * 2767 ^ 11)
pi = a / (a + b)
pi
```

```
## [1] 0.7597182
```

```
1 - pi
```

```
## [1] 0.2402818
```

LearnBayes の場合は以下のようになる.

```
probs = c(0.5, 0.5)
gamma.par1 = c(1.5, 1000)
gamma.par2 = c(7, 1000)
gammapar = rbind(gamma.par1, gamma.par2)
data = data.frame(t = 1767, y = 4)
post = poisson.gamma.mix(probs, gammapar, data)
post
```


```
## $probs
## gamma.par1 gamma.par2
## 0.7597182 0.2402818
##
## $gammapar
##           [,1] [,2]
## gamma.par1  5.5 2767
## gamma.par2 11.0 2767
```

```
(c)
lambda = seq(0, 1, by = 0.001)
g = function (lambda) {
```

```

0.5 * dgamma(lambda, shape = 1.5, rate = 1000) + 0.5 * dgamma(lambda,
  shape = 7, rate = 1000)
}
post = function (lambda) {
  pi * dgamma(lambda, shape = 5.5, rate = 2767) + (1 - pi) * dgamma(lambda,
    shape = 11, rate = 2767)
}
plot(lambda, g(lambda), xlim = c(0, 0.02), ylim = c(0, 500), ylab = "",
  type = "l", lty = 2)
par(new=T)
plot(lambda, post(lambda), xlim = c(0, 0.02), ylim = c(0, 500), ylab = "",
  type = "l")

```



(d)

$P(\lambda > 0.005) = 1 - P(\lambda \leq 0.005) = 1 - \int_0^{0.005} p(\lambda) d\lambda$ である.

数値積分

```

p = function (lambda) {
  return(pi * dgamma(lambda, shape = 5.5, rate = 2767) + (1 - pi) * dgamma(
    lambda, shape = 11, rate = 2767))
}
int = integrate(p, lower = 0, upper = 0.005)

```

```

1 - int$value

## [1] 0.04766545

# サンプリング近似
post_sample = function () {
  x = sample(c(0, 1), 1, prob = c(1 - pi, pi))
  if (x == 1) {
    return(rgamma(1, shape = 5.5, rate = 2767))
  } else {
    return(rgamma(1, shape = 11, rate = 2767))
  }
}
sample = replicate(100000, post_sample())
sum(sample > 0.005) / 100000

## [1] 0.04825

# グリッド近似
lambda = seq(0, 1, by = 0.000001)
p = function (lambda) {
  pi * dgamma(lambda, shape = 5.5, rate = 2767) + (1 - pi) * dgamma(lambda,
    shape = 11, rate = 2767)
}
post = p(lambda) / sum(p(lambda))
sum(cbind(lambda, post)[lambda > 0.005, 2])

## [1] 0.04763969

```

(e)

混合確率は、 $g_1(\lambda), g_2(\lambda)$ のそれぞれ 0.7597182、0.2402818 となっているので、このデータは $g_1(\lambda)$ に適合していると考えられる。

3-8

$$f(y : \lambda) = \text{Exp}(y|\lambda)F(y; \lambda) = \int_{-\infty}^y f(y : \lambda)dy$$

であるとする。

平均 λ の指数分布にしたがう電球 12 個のテストする。4 番目に短い寿命である $y_4 = 100$ であるので、1 ~ 3 番目までは 100 時間までに切れる確率であるので、 $F(100; \lambda)^3$ とできる。 $y_4 = 100$ となる確率 (密度) は $f(100; \lambda)$ である。8 番目に短い寿命である $y_8 = 300$ であるので、5 ~ 7 番目までは 100 ~ 300 時間までに切れる確率であるので、 $(F(300; \lambda) - F(100; \lambda))^3$ とできる。 $y_8 = 300$ となる確率 (密度) は $f(300; \lambda)$ である。9 ~ 12 番目は 300 ~ 時間で切れる確率であるので、 $(1 - F(300; \lambda))^4$ であるので、尤度関数は以下になる。

$$L(\lambda) \propto F(100; \lambda)^3 f(100; \lambda) (F(300; \lambda) - F(100; \lambda))^3 f(300; \lambda) (1 - F(300; \lambda))^4$$

(a)

事前分布は以下とする。

$$p(\lambda) \propto \frac{1}{\lambda}$$

事後分布は以下になる。

$$\begin{aligned} p(\lambda|data) &\propto L(\lambda)p(\lambda) \\ &= F(100; \lambda)^3 f(100; \lambda) (F(300; \lambda) - F(100; \lambda))^3 f(300; \lambda) (1 - F(300; \lambda))^4 \frac{1}{\lambda} \end{aligned}$$

グリッド近似を用いる

```
lambda = seq(0.1, 1000, by = 0.1)
```

```
p = function (lambda) {
```

```
  likelihood = pexp(100, 1/lambda)^3 * dexp(100, 1/lambda) * (pexp(300, 1/lambda) - pexp(100, 1/lambda))^3 * dexp(300, 1/lambda) * (1 - pexp(300, 1/lambda))^4
```


```
  return(likelihood / lambda)
```

```
}
```

```
post = p(lambda)
```

```
post = post / sum(post)
```

```
plot(lambda, post, type = "l")
```



(b)

グリッド近似を用いる

```
lambda = seq(0.1, 1000, by = 0.1)
```

```
p = function (lambda) {
```

```
  likelihood = pexp(100, 1/lambda)^3 * dexp(100, 1/lambda) * (pexp(300, 1/
    lambda) - pexp(100, 1/lambda))^3 * dexp(300, 1/lambda) * (1 - pexp
    (300, 1/lambda))^4
```

```
  return(likelihood / lambda)
```

```
}
```

```
post = p(lambda)
```

```
post = post / sum(post)
```

```
mu = sum(lambda * post)
```

```
mu
```

```
## [1] 327.2188
```

```
sqrt(sum((lambda - mu)^2 * post))
```

```
## [1] 127.6595
```

(c)


```

# グリッド近似を用いる
lambda = seq(0.1, 1000, by = 0.1)
p = function (lambda) {
  likelihood = pexp(100, 1/lambda)^3 * dexp(100, 1/lambda) * (pexp(300, 1/
    lambda) - pexp(100, 1/lambda))^3 * dexp(300, 1/lambda) * (1 - pexp
    (300, 1/lambda))^4
  return(likelihood / lambda)
}
post = p(lambda)
post = post / sum(post)
sum(cbind(lambda, post)[300 < lambda & lambda < 500, 2])

## [1] 0.4059514

```

4-1